

# 統計的機械学習

## 第5回 混合ガウスモデル1

2013/06/25



表現工学科 尾形研究室 ゼミ

野田 邦昭

## ■ ガウスモデル＋最尤推定：

- モデルが(大体)正しい場合，訓練標本数が比較的少なくても推定精度が良い
- モデルが単純なため，表現できる確率密度関数の形が限られる

$$q(x; \mu, \Sigma) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(x - \mu)^T \Sigma^{-1}(x - \mu)\right)$$




## ■ ガウスクERNEL密度推定:

- 任意の確率密度関数を近似できる
- 精度良く近似するためには多数の訓練標本が必要

$$\hat{p}(x) = \frac{1}{nh^d} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right)$$

$$K(x) = \frac{1}{(2\pi)^{d/2}} \exp\left(-\frac{1}{2} x^T x\right)$$



# ガウス混合モデル

193

## ■ ガウス混合モデル(Gaussian mixture model):

$$q(x; \theta) = \sum_{j=1}^m w_j \phi(x; \mu_j, \sigma_j)$$

$$w_j \geq 0, \sum_{j=1}^m w_j = 1$$

$$\theta = (w_1, \dots, w_m, \mu_1^T, \dots, \mu_m^T, \sigma_1, \dots, \sigma_m)^T$$

$$\mu_j \in \mathbb{R}^d, \sigma_j > 0$$

$$\phi(x; \mu, \sigma) = \frac{1}{(2\pi\sigma^2)^{d/2}} \exp\left(-\frac{(x - \mu)^T (x - \mu)}{2\sigma^2}\right)$$



$m$ : 混合数

## ■ 注意: $q(x; \theta)$ は確率密度関数なので

$$\int_D q(x; \theta) dx = 1 \quad \forall x \in D, q(x; \theta) \geq 0$$

を満たす.

## ■ 有限個のガウスモデルの線形結合：



- 通常のガウスモデルよりも複雑な確率密度関数を表現できる.
- ガウスカーネル密度推定より単純なので, 訓練標本が比較的少ない場合でも推定精度が良い.

# ガウス混合モデルの最尤推定 195

- **最尤推定**: (対数)尤度 (訓練標本  $\{x_i\}_{i=1}^n$  が生成される確率) を最大にするように  $\theta$  を定める

$$\log L(\theta) = \sum_{i=1}^n \log q(x_i; \theta) = \sum_{i=1}^n \log \sum_{j=1}^m w_j \phi(x_i; \mu_j, \sigma_j)$$

- 但し, **拘束条件**  $w_j \geq 0, \sum_{j=1}^m w_j = 1$  を考慮しなければならぬ!

- $w_j = \frac{\exp(\gamma_j)}{\sum_{j'=1}^m \exp(\gamma_{j'})}$  とおき,  $\gamma_j \in \mathbb{R}$  を決定する

ことにすれば, 拘束条件は自動的に満たされる.

# 尤度方程式

## ■ 最尤推定解の必要条件:

$$\frac{\partial \log L}{\partial \gamma_j} = 0, \quad \frac{\partial \log L}{\partial \mu_j} = 0, \quad \frac{\partial \log L}{\partial \sigma_j} = 0$$

より, 最尤推定解は以下を満たす(証明は宿題)

$$\hat{w}_j = \frac{1}{n} \sum_{i=1}^n \hat{\eta}_{i,j}$$

$$\hat{\sigma}_j = \sqrt{\frac{1}{d} \frac{\sum_{i=1}^n \hat{\eta}_{i,j} (x_i - \hat{\mu}_j)^T (x_i - \hat{\mu}_j)}{\sum_{i'=1}^n \hat{\eta}_{i',j}}}$$

$$\hat{\mu}_j = \frac{\sum_{i=1}^n \hat{\eta}_{i,j} x_i}{\sum_{i'=1}^n \hat{\eta}_{i',j}}$$

$$\hat{\eta}_{i,j} = \frac{\hat{w}_j \phi(x_i; \hat{\mu}_j, \hat{\sigma}_j)}{\sum_{j'=1}^m \hat{w}_{j'} \phi(x_i; \hat{\mu}_{j'}, \hat{\sigma}_{j'})}$$

$d : x$ の次元

## ■ しかし, この連立方程式は簡単に解けない.

## ■ 勾配法(gradient method):


1. 適当に初期値  $\hat{\theta}^{(0)}$  を定める.
2. 勾配を上るようにパラメータを更新する:

$$\hat{\theta}^{(t+1)} \leftarrow \hat{\theta}^{(t)} + \varepsilon \frac{\partial \log L}{\partial \theta} \bigg|_{\theta=\hat{\theta}^{(t)}}$$

$\varepsilon$  : 小さい正のスカラー


3. 収束するまで勾配上昇を繰り返す.

## ■ 局所最適解(local optimal solution)が求まる.





## ■ 学習率 $\varepsilon$ の選び方が難しい:



- $\varepsilon$  は、「最初大きく、徐々に小さく」が原則だが、適切に決定することは難しい

## ■ 局所最適解しか見つけられない:

- 様々な初期値から何度か学習し、最適な値を採用する